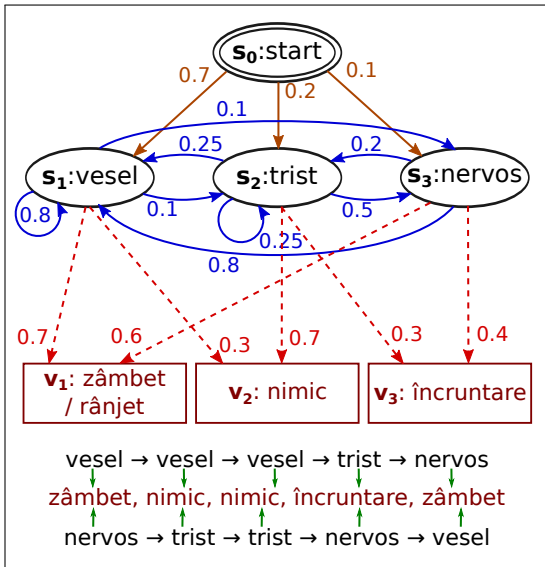


Exemplu: Urmărirea stărilor emoționale



O - secvența de observații

T - lungimea secvenței de observații

$$O = [o_1 o_2 \cdots o_T]$$




Modele Markov Ascunse

Definiție

Un **Model Markov Ascuns** este un tuplu $\langle S, V, A, B, P \rangle$:

- S - mulțimea stărilor
- V - mulțimea valorilor observabile
- A - matricea de tranziție
- B - matricea de emisie
- Π - matricea distribuției stării inițiale
- Notăție: $\lambda = (A, B, \Pi)$ - parametrii modelului





Reformularea problemelor fundamentale ale MMA

Problema evaluării

Date fiind un model $\lambda = (A, B, \Pi)$ și o secvență de observații $O = [o_1 o_2 \cdots o_T]$, cum calculăm probabilitatea $P(O|\lambda)$ ca secvența de observații să fi fost generată de acel model?

- Prin enumerarea tuturor secvențelor posibile de stări:

$$P(O|\lambda) = \sum_{\text{all } Q} P(O|Q, \lambda) \cdot P(Q|\lambda) \quad (1)$$

(legea probabilității totale)



Reformularea problemelor fundamentale ale MMA

$$P(O|\lambda) = \sum_{\text{all } Q} P(O|Q, \lambda) \cdot P(Q|\lambda) \quad (1)$$

Primul factor (independență condițională):

$$P(O|Q, \lambda) = \prod_{t=1}^T P(o_t|q_t, \lambda) = \prod_{t=1}^T b_{q_t}(o_t) = b_{q_1}(o_1) \cdot \dots \cdot b_{q_T}(o_T) \quad (2)$$

Al doilea factor (presupunerea Markov):

$$P(Q|\lambda) = \pi_{q_1} \prod_{t=2}^T a_{q_{t-1}, q_t} = \pi_{q_1} \cdot a_{q_1, q_2} \cdot a_{q_2, q_3} \cdot \dots \cdot a_{q_{T-1}, q_T} \quad (3)$$

$$P(O|\lambda) = \sum_{\text{all } Q} \left(\pi_{q_1} \cdot b_{q_1}(o_1) \cdot \prod_{t=2}^T b_{q_t}(o_t) a_{q_{t-1}, q_t} \right) \quad (1)$$



Reformularea problemelor fundamentale ale MMA

Problema interpretării unei secvențe de observații

Date fiind un model $\lambda = (A, B, \Pi)$ și o secvență de observații $O = [o_1 o_2 \cdots o_T]$, cum alegem o secvență corespunzătoare de stări $Q = [q_1 q_2 \cdots q_T]$ care să dea un înțeles observațiilor? Cum descoperim partea ascunsă a modelului?

- Cum alegem criteriul pentru cea mai bună secvență?
 - Secvența celor mai probabile stări (luate individual):

$$Q_{\text{best}} = [q_{1_{\text{best}}} \ q_{2_{\text{best}}} \ \cdots \ q_{T_{\text{best}}}], \quad q_{t_{\text{best}}} = \underset{s_i}{\operatorname{argmax}} P(q_t = s_i | O, \lambda) \quad (4)$$

- Cea mai bună cale (de dimensiune T)

$$Q_{\text{best}} = \underset{Q}{\operatorname{argmax}} P(Q | O, \lambda) = \underset{Q}{\operatorname{argmax}} P(Q, O | \lambda) \quad (5)$$



Algoritmul Forward-Backward

Problema Evaluării

Date fiind un model $\lambda = (A, B, \Pi)$ și o secvență de observații $O = [o_1 o_2 \dots o_T]$, care este probabilitatea ca secvența de observații să fi fost produsă de acel model?

$$P(O|\lambda) = ? \quad (7)$$

Rezolvare

$P(O|\lambda)$ se calculează *eficient* cu algoritmul **Forward - Backward**.

Calculul se face cu ajutorul unor variabile auxiliare α și β .



Variabilele α - Motivație

- Calcul conform legii probabilităților totale:

$$\begin{aligned}
 P(O|\lambda) &= \sum_{all\ Q} P(O, Q|\lambda) = \sum_{all\ Q} P(O, |Q, \lambda) \cdot P(Q, \lambda) \\
 &= \sum_{all\ Q} \left(\pi_{q_1} \cdot b_{q_1}(o_1) \cdot \prod_{t=2}^T b_{q_t}(o_t) a_{q_{t-1}, q_t} \right)
 \end{aligned}
 \tag{1}$$

- Pentru secvențele de stări care încep cu o secvență comună $[q_1 q_2 \dots q_Z]$, următorii factori sunt comuni:

$$\pi_{q_1} \cdot b_{q_1}(o_1) \cdot \prod_{z=2}^Z b_{q_z}(o_z) a_{q_{z-1}, q_z}$$

- Calculul de $(T - Z)^N$ ori ar fi redundant!



Variabilele α - Definiție

Definim variabilele α astfel:

$$\alpha_{t,i} = P(o_1, o_2, \dots, o_t, q_t = s_i | \lambda) \quad (8)$$
$$1 \leq t \leq T, 1 \leq i \leq N$$

(probabilitatea de a fi observat primele t valori observate ajungând la momentul t în starea s_i , dați fiind parametrii λ)



Variabilele α - Definiție

Definim variabilele α astfel:

$$\alpha_{t,i} = P(o_1, o_2, \dots, o_t, q_t = s_i | \lambda) \quad (8)$$
$$1 \leq t \leq T, 1 \leq i \leq N$$

(probabilitatea de a fi observat primele t valori observate ajungând la momentul t în starea s_i , dați fiind parametrii λ)

Relația dintre $P(O|\lambda)$ și variabilele α este:

$$P(O|\lambda) = \sum_{i=1}^N \alpha_{T,i} \quad (9)$$

(conform legii probabilităților totale)



Calculul variabilelor α

- Inițializare ($t = 1$)


$$\alpha_{1,i} = \pi_i b_i(o_1), \quad 1 \leq i \leq N$$

- Inducție ($t > 1$)

$$\alpha_{t+1,j} = \left[\sum_{i=1}^N \alpha_{t,i} a_{i,j} \right] b_j(o_{t+1}), \quad \begin{matrix} 1 \leq t \leq T-1 \\ 1 \leq j \leq N \end{matrix}$$

- Probabilitatea secvenței observate:

$$P(O|\lambda) = \sum_{i=1}^N \alpha_{T,i}$$





Variabilele β - Definiție

Definim variabilele β astfel:

$$\beta_{t,i} = P(o_{t+1}o_{t+2} \cdots o_T | q_t = s_i, \lambda) \quad (10)$$

(probabilitatea de a fi observate valorile secvenței de la $t + 1$ la T , condiționată de aflarea la momentul t în starea s_i și de parametrii λ)

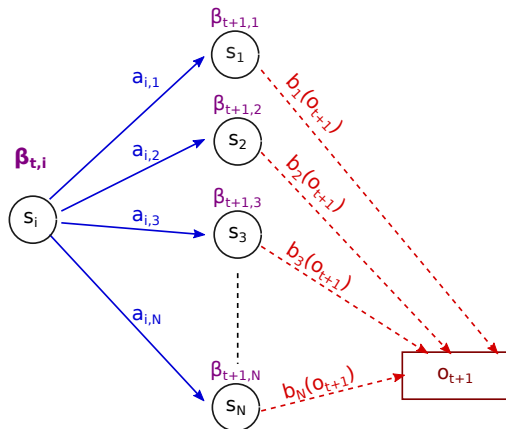
Relația dintre $P(O|\lambda)$ și variabilele β este:

$$P(O|\lambda) = \sum_{i=1}^N \beta_{1,i} \quad (11)$$

(conform legii probabilităților totale)



Calculul Variabilelor β



- Inițializare ($t = T$)

$$\beta_{T,i} = 1, \quad 1 \leq i \leq N \quad (12)$$

- Pas de inducție ($t < T$)

$$\beta_{t,i} = \sum_{j=1}^N a_{i,j} b_j(o_{t+1}) \beta_{t+1,j}, \quad t = T-1, T-2, \dots, 1, 1 \leq i \leq N$$



Problema interpretării

Problema interpretării unei secvențe de observații

Date fiind un model $\lambda = (A, B, \Pi)$ și o secvență de observații $O = [o_1 o_2 \cdots o_T]$, cum alegem o secvență corespunzătoare de stări $Q_{\text{best}} = [q_{1_{\text{best}}} q_{2_{\text{best}}} \cdots q_{T_{\text{best}}}]$ care să dea un înțeles observațiilor? Cum descoperim partea ascunsă a modelului?

- Răspunsul depinde de criteriul cu care alegem cea mai bună secvență
 - secvența celor mai probabile stări $q_{t_{\text{best}}}$ (luate individual), date fiind modelul și secvența observată:

$$q_{t_{\text{best}}} = \underset{s_i}{\operatorname{argmax}} P(q_t = s_i | O, \lambda)$$
 - cea mai probabilă secvență de stări Q (per ansamblu), date fiind modelul și secvența observată:

$$Q_{\text{best}} = \underset{\text{all } Q}{\operatorname{argmax}} P(Q | O, \lambda)$$



Secvența celor mai probabile stări

Notăție: $P(q_t = s_i | O, \lambda) = \gamma_{t,i} = \frac{\alpha_{t,i} \beta_{t,i}}{\sum_{j=1}^N \alpha_{t,j} \beta_{t,j}}$

- Este un criteriu satisfăcător?



Secvența celor mai probabile stări

Notăție: $P(q_t = s_i | O, \lambda) = \gamma_{t,i} = \frac{\alpha_{t,i} \beta_{t,i}}{\sum_{j=1}^N \alpha_{t,j} \beta_{t,j}}$

- Este un criteriu satisfăcător?

- **NU!**

Pot exista q_t și q_{t+1} astfel încât $a_{q_t, q_{t+1}} = 0$



Algoritmul Viterbi

- Criteriu care ia în considerare distribuțiile de probabilitate ale tranzițiilor între stări
- Cea mai bună cale: $Q_{\text{best}} = [q_{1_{\text{best}}} q_{2_{\text{best}}} \cdots q_{T_{\text{best}}}]$

$$Q_{\text{best}} = \underset{Q}{\operatorname{argmax}} P(Q|O, \lambda) = \underset{Q}{\operatorname{argmax}} P(Q, O|\lambda) \quad (6)$$

- **Algoritmul Viterbi** - programare dinamică [Vit67]
- Vom introduce variabilele δ .



Variabilele δ - intuiție

Întrebare

Dacă $Q = [q_1, q_2, \dots, q_{t-1}, q_t]$ este cea mai bună secvență care explică $O = [o_1, o_2, \dots, o_{t-1}, o_t]$, atunci putem afirma că $Q[1 : t - 1]$ este cea mai bună secvență de stări care explică $O[1 : t - 1]$?



Variabilele δ - intuiție

Întrebare

Dacă $Q = [q_1, q_2, \dots, q_{t-1}, q_t]$ este cea mai bună secvență care explică $O = [o_1, o_2, \dots, o_{t-1}, o_t]$, atunci putem afirma că $Q[1 : t - 1]$ este cea mai bună secvență de stări care explică $O[1 : t - 1]$?

- NU!**

$$P(q_1 = s_{i_1}, q_2 = s_{i_2}, \dots, q_{t-1} = s_{i_{t-1}}, q_t = s_{i_t} | O, \lambda) = \\ P(q_1, q_2, \dots, q_{t-1} | O, \lambda) \cdot P(q_t = s_{i_t} | q_{t-1} = s_{i_{t-1}}, \lambda) \cdot P(o_t | q_t = s_{i_t}, \lambda)$$



Variabilele δ

- Vom numi variabile δ :

$$\delta_{t,i} = \max_{q_1, \dots, q_{t-1}} P([q_1 q_2 \dots q_{t-1} s_i], [o_1, o_2, \dots o_t] | \lambda) \quad (26)$$

- $\delta_{t,i}$ - cea mai mare probabilitate a unei secvențe de stări de lungime t care ajunge în s_i și explică primele t valori observate



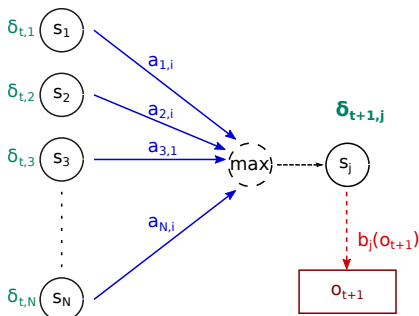
Variabilele δ

- Vom numi variabile δ :

$$\delta_{t,i} = \max_{q_1, \dots, q_{t-1}} P([q_1 q_2 \dots q_{t-1} s_i], [o_1, o_2, \dots o_t] | \lambda) \quad (26)$$

- $\delta_{t,i}$ - cea mai mare probabilitate a unei secvențe de stări de lungime t care ajunge în s_i și explică primele t valori observate
- relația dintre variabilele δ :

$$\delta_{t+1,j} = [\max_i \delta_{t,i} \cdot a_{i,j}] \cdot b_j(o_{t+1}) \quad (27)$$





Algoritmul Viterbi - Privire de ansamblu

Pași înainte

Calculăm cea mai mare probabilitate de a ajunge în starea s_i la momentul t pe baza celor mai mari probabilități de a fi ajuns în toate stările s_j la $t - 1$.



Algoritmul Viterbi - Privire de ansamblu

Pași înainte

Calculăm cea mai mare probabilitate de a ajunge în starea s_i la momentul t pe baza celor mai mari probabilități de a fi ajuns în toate stările s_j la $t - 1$.

La final ($t = T$)

Starea finală este acea stare s_i cu cea mai mare probabilitate de a ajunge la ea după observarea tuturor valorilor.



Algoritmul Viterbi - Privire de ansamblu

Pași înainte

Calculăm cea mai mare probabilitate de a ajunge în starea s_i la momentul t pe baza celor mai mari probabilități de a fi ajuns în toate stările s_j la $t - 1$.

La final ($t = T$)

Starea finală este acea stare s_i cu cea mai mare probabilitate de a ajunge la ea după observarea tuturor valorilor.

Pași înapoi

Refacem *cea mai bună cale* alegând pentru fiecare moment t starea care a dus la probabilitatea maximă pentru starea de la $t + 1$.



Algoritmul Viterbi (I)

1 Inițializare:

$$\begin{aligned}\delta_{1,i} &= \pi_i b_i(o_1), \quad 1 \leq i \leq N \\ \psi_{1,i} &= 0\end{aligned}\tag{28}$$

2 Recursivitate:

$$\begin{aligned}\delta_{t,j} &= [\max_i \delta_{t-1,i} \cdot a_{i,j}] \cdot b_j(o_t) \quad 2 \leq t \leq T, 1 \leq j \leq N \\ \psi_{t,j} &= \operatorname{argmax}_i \delta_{t-1,i} \cdot a_{i,j} \quad 2 \leq t \leq T, 1 \leq j \leq N\end{aligned}\tag{29}$$



Algoritmul Viterbi (II)

3 Terminare:

$$\begin{aligned} P(Q_{\text{best}}|O, \lambda) &= \max_i \delta_{T,i} \\ q_{T_{\text{best}}} &= \operatorname{argmax}_i \delta_{T,i} \end{aligned} \quad (30)$$

4 Backtracking:

$$q_{t_{\text{best}}} = \psi_{t+1}(q_{t+1_{\text{best}}}), \quad t=T-1, T-2, \dots, 1 \quad (31)$$



Probleme numerice

- Cine este $P(Q_{\text{best}}|O, \lambda)$?

$$P(Q_{\text{best}}|O, \lambda) = \delta_{T, i_T}$$

$$P(Q_{\text{best}}|O, \lambda) = \delta_{T-1, i_{T-1}} \cdot a_{i_{T-1}, i_T} \cdot b_T(o_T)$$

$$P(Q_{\text{best}}|O, \lambda) = \delta_{T-2, i_{T-2}} \cdot a_{i_{T-2}, i_{T-1}} \cdot b_{T-1}(o_{T-1}) \cdot a_{i_{T-1}, i_T} \cdot b_T(o_T)$$

$$P(Q_{\text{best}}|O, \lambda) = \prod \dots$$

- Cum putem evita apropierea rapidă de zero?



Probleme numerice

- Cine este $P(Q_{\text{best}}|O, \lambda)$?

$$P(Q_{\text{best}}|O, \lambda) = \delta_{T, i_T}$$

$$P(Q_{\text{best}}|O, \lambda) = \delta_{T-1, i_{T-1}} \cdot a_{i_{T-1}, i_T} \cdot b_T(o_T)$$

$$P(Q_{\text{best}}|O, \lambda) = \delta_{T-2, i_{T-2}} \cdot a_{i_{T-2}, i_{T-1}} \cdot b_{T-1}(o_{T-1}) \cdot a_{i_{T-1}, i_T} \cdot b_T(o_T)$$

$$P(Q_{\text{best}}|O, \lambda) = \prod \dots$$

- Cum putem evita apropierea rapidă de zero?
- Calculăm $\log(P)$

$$\log(P(Q_{\text{best}}|O, \lambda)) = \log(\delta_{T, i_T})$$

$$\log(P(Q_{\text{best}}|O, \lambda)) = \log(\delta_{T-1, i_{T-1}}) + \log(a_{i_{T-1}, i_T}) + \log(b_T(o_T))$$

$$\log(P(Q_{\text{best}}|O, \lambda)) = \log(\delta_{T-2, i_{T-2}}) + \log(a_{i_{T-2}, i_{T-1}}) + \log(b_{T-1}(o_{T-1})) + \log(a_{i_{T-1}, i_T}) + \log(b_T(o_T))$$

$$\log(P(Q_{\text{best}}|O, \lambda)) = \sum \dots$$



Probleme numerice - Rezolvare

- Notăție:

$$\phi_{t,i} = \max_{q_1, \dots, q_{t-1}} \log(P(q_1, \dots, q_{t-1}, q_t = s_i, o_1, \dots, o_t | \lambda)) = \log(\delta_{t,i})$$

- Matricele $\log(\Pi)$, $\log(A)$ și $\log(B)$ pot fi precalculate.



Algoritmul Viterbi - $\log(P)$ (I)

1 Inițializare:

$$\begin{aligned}\phi_{1,i} &= \log(\pi_i) + \log(b_i(o_1)), & 1 \leq i \leq N \\ \psi_{1,i} &= 0\end{aligned}\quad (32)$$

2 Recursivitate:

$$\begin{aligned}\phi_{t,j} &= [\max_i \phi_{t-1,i} + \log(a_{i,j})] + \log(b_j(o_t)) & 2 \leq t \leq T, 1 \leq j \leq N \\ \psi_{t,i} &= \operatorname{argmax}_i \phi_{t-1,i} + \log(a_{i,j}) & 2 \leq t \leq T, 1 \leq j \leq N\end{aligned}\quad (33)$$



Algoritmul Viterbi - $\log(P)$ (II)

3 Terminare:

$$\begin{aligned}\log(P(Q_{\text{best}}|O, \lambda)) &= \max_i \phi_{T,i} \\ q_{T_{\text{best}}} &= \operatorname{argmax}_i \phi_{T,i}\end{aligned}\tag{34}$$

4 Backtracking:

$$q_{t_{\text{best}}} = \psi_{t+1}(q_{t+1_{\text{best}}}), \quad t=T-1, T-2, \dots, 1\tag{35}$$